


位相的データ解析の紹介

MT部 DSチーム 山本

2025/11/13

Topological Data Analysis (TDA)

トポロジー（位相幾何学）を用いてデータの「形」を分析する手法の総称



Persistent Homology

単体復体

- k 単体 $|p_0 p_1 \cdots p_k| = \{x \in \mathbb{R}^k \mid x = \sum_{i=0}^k \lambda_i p_i, \sum_{i=0}^k \lambda_i = 1\}$
 - 例: 0単体 (点)、1単体 (辺)、2単体 (正三角形)、3単体 (四面体)
 - 例: 2単体 $|p_0 p_1 p_2|$ は、7つの面 $|p_0|, |p_1|, |p_2|, |p_0 p_1|, |p_0 p_2|, |p_1 p_2|, |p_0 p_1 p_2|$ をもつ。
- 有限個の単体の集まり K が次の条件を満たす時、**単体復体**と呼ぶ:
 1. K に属する単体 τ の面 σ もまた K に含まれる
 2. 2つの単体 $\tau, \sigma \in K$ の空でない共通部分 $\tau \cap \sigma$ は τ の面であり、 σ の面でもある




図 1.1 点, 辺, 三角形, 四面体

Homology

- 1単体が作る「穴」 = 「**境界**のない1単体の集まりであって2単体の集まりの**境界**になっていないもの」
- n 次元単体複体 K に属する k 単体の集まりを K_k とし、 k 鎖群 (K_k で生成される自由 \mathbb{Z} 加群) $C_k(K)$ を定義:

$$C_k(K) = \left\{ c = \sum_{\sigma \in K_k} \alpha_{\sigma} \langle \sigma \rangle \mid a_{\sigma} \in \mathbb{Z} \right\}$$

- 境界作用素 $\partial_k : C_k(K) \rightarrow C_{k-1}(K)$ を定義すると、
 - $\text{Ker} \partial_k = \{ \sigma \in C_k(K) \mid \partial_k(\sigma) = 0 \}$ は境界のない k 単体
 - $\text{Im} \partial_k = \{ \sigma \in C_k(K) \mid \sigma = \partial_k(\tau), \tau \in C_{k+1}(K) \}$ は $k+1$ 単体の境界となっている k 単体
 - k 次のホモロジー群: $H_k(K) = \text{Ker} \partial_k / \text{Im} \partial_{k+1}$




図 2.4 1 単体が作る「穴」

Persistent Homology (パーシステントホモロジー)


- 点群 X の「形状」を抽出する手法
- 各点 $x \in X$ を中心とした半径 r の集合 $B(X; r) = \bigcup_{x \in X} B(x; r)$ に対して、 r を大きくしていくとフィルトレーションを得る:

$$\mathbb{B}(X) : \cdots \subset B(X; a) \subset B(X; b) \subset \cdots \quad (a < b)$$

- ホモロジー群の系列 (q 次元パーシステントホモロジー) も得る:



$$H_q(\mathbb{B}(X)) : \cdots \rightarrow H_q(B(X; a)) \xrightarrow{u_a^b} H_q(B(X; b)) \rightarrow \cdots \quad (a < b)$$

- 分解定理により $H_q(\mathbb{B}(X)) \simeq \bigoplus_{i \in I} \mathbb{I}[b_i, d_i]$ と区間表現でき、これを \mathbb{R}^2 に表示した多重集合 $D_q(X) = \{(b_i, d_i) \mid i \in I\}$ を q 次元パーシステントダイアグラムと呼ぶ。



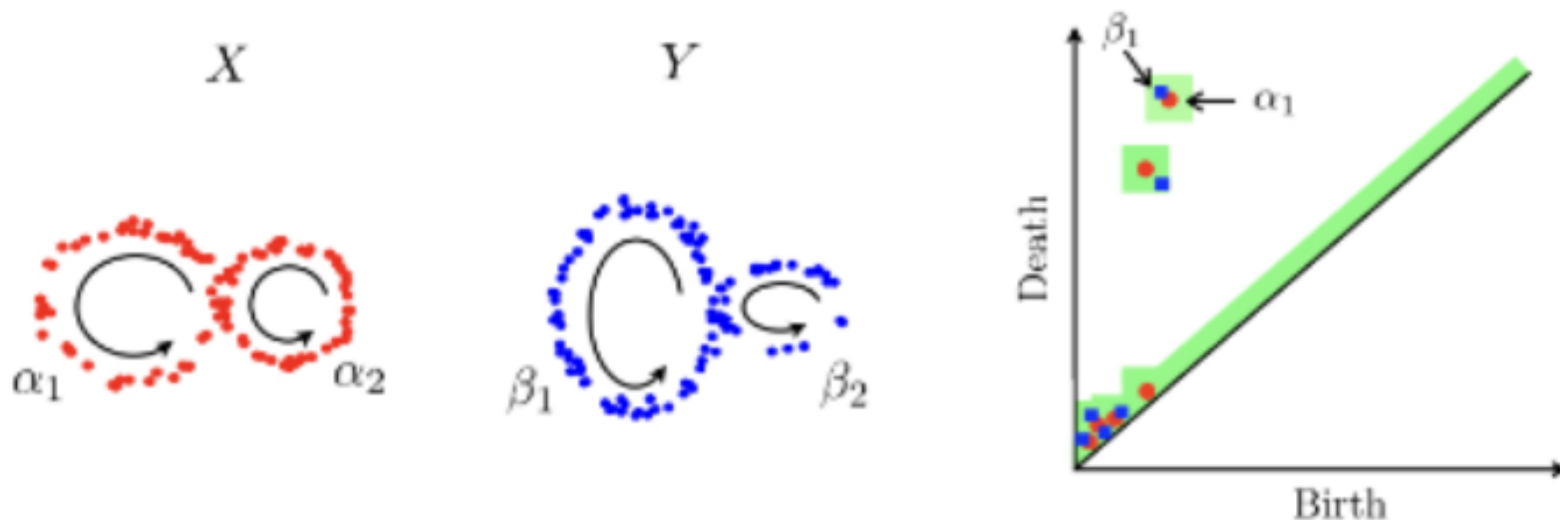
Persistent Homology の具体例

- パーシステントホモロジーとは「各点を太らせたときにできる"穴"の生成消滅の系列」とざっくり理解
- 例えば、
 - $r = b_1$ のとき、穴 α_1 が発生
 - $r = b_2$ のとき、穴 α_2 が発生
 - $r = d_2$ のとき、穴 α_2 消滅
 - $r = d_1$ のとき、穴 α_1 が消滅



Persistent Homology の魅力の一部分

- フィルトレーションを構成できれば、点群以外のあらゆるデータに対してパーシステントホモロジーを計算可能
- 摂動でパーシステントダイアグラム (PD) は大きく変わらない
 - PD の安定性解析も主テーマとなっている (例: $d_b(D(\mathcal{C}(X)), D(\mathcal{C}(Y))) \leq d_H(X, Y)$)

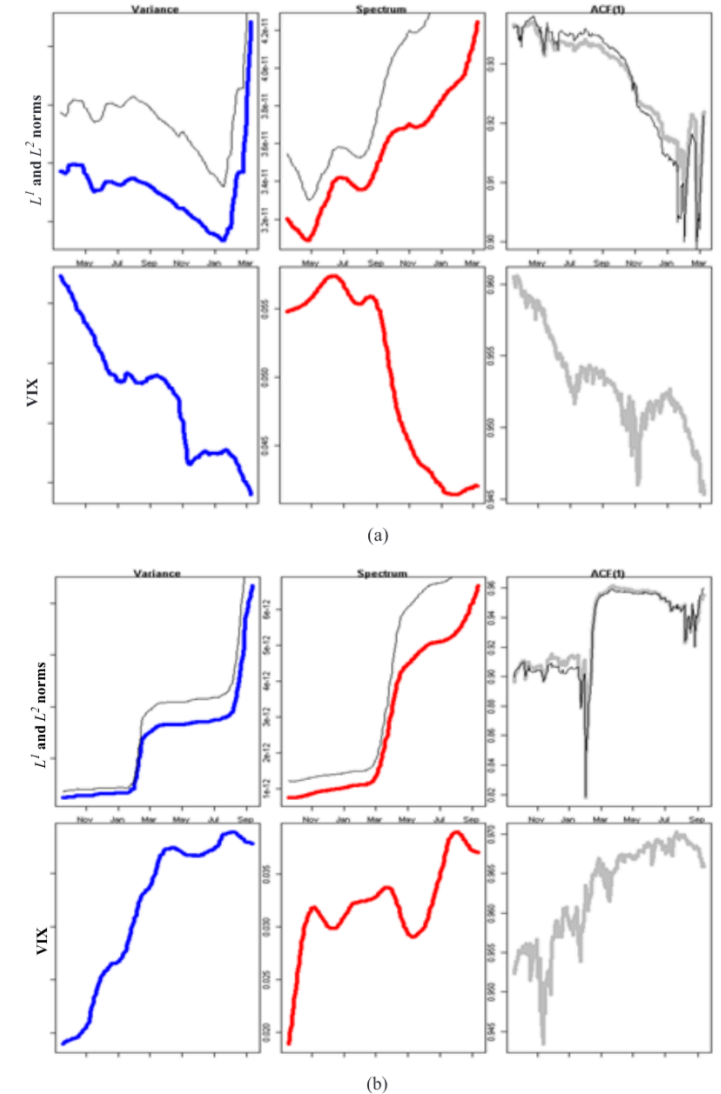


- TDA X 統計的機械学習の分野も盛ん

Persistent Homology の応用例

金融危機予兆（異常検知）への応用

- [Gidea and Katz 2018](#) は金融市場にパーシステントホモロジーを適応した草分け的な研究
 - 米国株式指数（S&P500など）の日次リターン系列を対象に分析
 - 時系列 → 遅延座標埋め込み → 1次のPD → パーシステントランドスケープの L^p 距離（位相的構造の全体的な大きさを示す指標）
 - (a)ドットコムバブル崩壊（2000年）および(b)リーマン・ショック（2008年）期で L^p の時系列の低周波成分が統計的優位に上昇
 - 右図は、各ショックの250日以前の（上） L^p 指標と（下）VIX に対して、（左）低周波成分が分散、（中央）低周波成分の平均、（右）1次の自己相関を示している
- 暗号通貨（[Gidea+2020](#)）、PH特徴量を機械学習モデルに利用（[Guritanu+2025](#)）など類似研究は割とある



Takens の埋め込み定理


- 力学系 $f : M \rightarrow M$ と 観測関数 $g : M \rightarrow \mathbb{R}$ を考える:

$$x_{t+1} = f(x_t), \quad s_t = g(x_t)$$

- 時間遅れ座標 $\Phi_{(f,g)} : M \rightarrow \mathbb{R}^{2m+1}$ は埋め込みとなる:

$$\Phi_{(f,g)}(x) = (g(x), g(f(x)), \dots, g(f^{2m}(x)))$$

- 例えば、米国の株式市場の「状態」 x_t を株価指数 (S&P500など) s_t で観測した場合、時間遅れ座標 $(s_t, s_{t+\tau}, \dots, s_{t+2m\tau})$ で x_t の挙動を再現できる。



Persistent Homology を遊んでみたかった

金融時系列への応用

すみません。間に合いませんでした。今後進展あったら共有します。


- 先行研究同様に、金融時系列の遅延座標埋め込みに対してTDAを実施
- 銘柄間や指標間の相関行列（距離行列 $d_{ij} = \sqrt{1 - \rho_{ij}^2}$ ）に対して閾値を設けることで、フィルトレーションを構築しTDAを実施

Mapper


Mapper

データの特徴となる部分を把握しやすくグラフとして表示する手法

(a) Two-Dimensional PCA



(b) Shape Graph by Mapper



Mapper のアルゴリズム

1. 点群 X から低次元空間 \mathbb{R}^k への写像 $f : X \rightarrow \mathbb{R}^k$ を与える
2. 像 $f(X)$ の被覆 $f(X) \subset \bigcup_i C_i$ を考えて、その逆像に $f^{-1}(C_i)$ により X を分割する
3. 各逆像 $f^{-1}(C_i)$ ($i = 0, 1, \dots$) ごとにクラスタリングする:


$$f^{-1}(C_i) = \bigsqcup_j V_{i,j}$$

4. $V_{i,j}$ をノードとして、2 頂点 U, V が元のデータ空間 X で共通部分を持つときエッジをはる


Step 1: Apply filter function.




Step 2: Cover the image, and partition data



Step 3: Perform clustering in each pre-image.

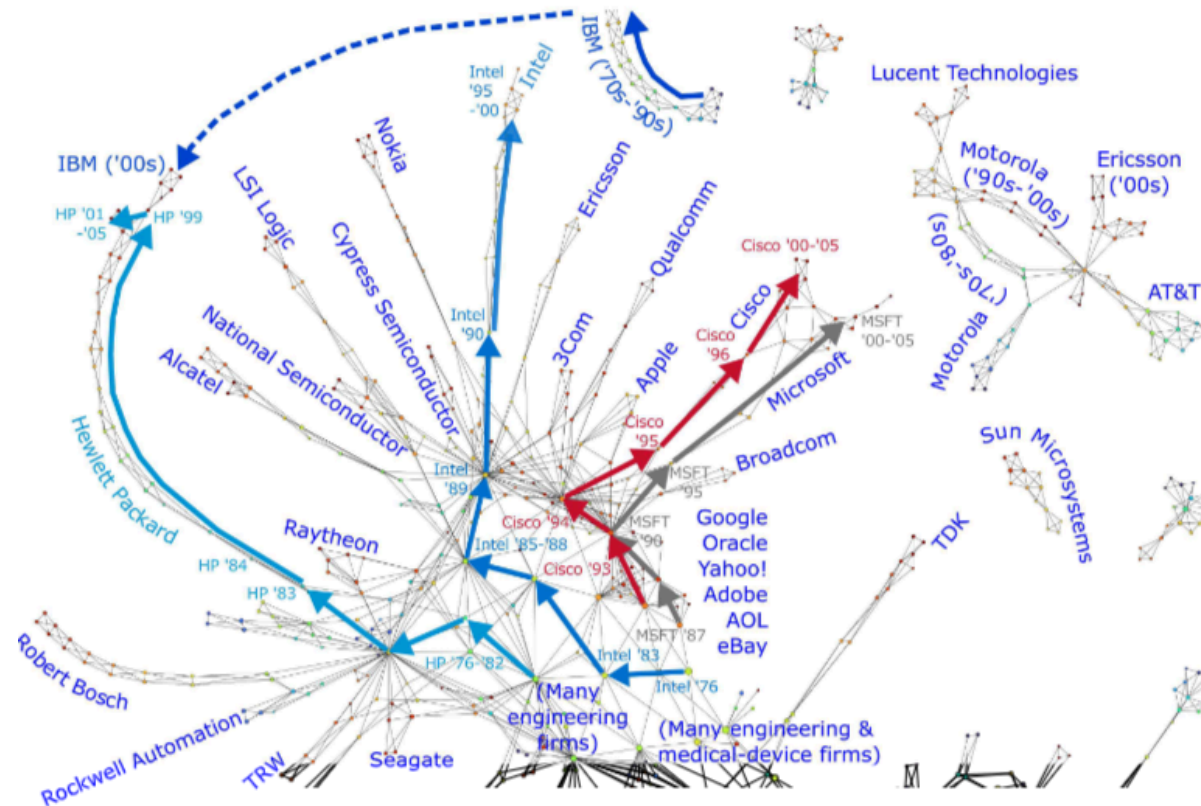


Step 4: Represent clusters by nodes, and shared points by edges.



Mapper の応用

- [Escobar+2022](#) では、企業の特許データを利用して、企業の技術戦略の可視化を実施。
- $X = \{p_{i,t} = (p_{i,t,1}, \dots, p_{i,t,S}) \in \mathbb{R}^S \mid i = 1, \dots, F, t = 0, \dots, T\}$
 - S 個の特許カテゴリ、 F 個の企業数、 T ステップ



参考図書とOSS

TDA の参考図書



- TDA の代表的な教科書
- 内容は難しいが、応用例が豊富



- Persistent Homology が中心
- 内容は難しいが、応用例が豊富



- Persistent Homology の入門書
- 学部程度の線形代数の知識で入門できることがありがたい

TDA OSS

GUDHI

गुढी

- C++ ライブラリ
- Pythonモジュールも提供
- Persistent Homology がメイン
- 様々なタイプの複体やデータ構造に対応

Giotto-tda



- Scikit-learn に準拠
- Persistent Homology, Mapper に対応

Ripser

- Vietoris-Rips 複体に対するパーシステントホモロジーを高速に計算するソフトウェア

RIVET

- 2 パーシステント加群に対応